

Pipeline DataOps E-Commerce

Integrantes:

- Diego Muñoz.
- Sofía Paillalef.

Sección: 002D.

Asignatura: Gestión de datos para IA.

Índice:

1° Resumen Ejecutivo	3
2° Justificación de Metodología	3
3° Planificación del Proyecto	4
4° Explicación Pipeline	7
5° Cumplimiento Normativo	10
6° Repositorio GitHub	10
7° Estrategias KP I	12
8° Conclusiones	13

1. Resumen Ejecutivo

Descripción del proyecto

La organización (e-commerce) recibe diariamente un archivo Excel con ventas alojado en Google Drive. Actualmente el equipo de análisis dedica horas a limpiar y validar manualmente los datos, generando retrasos y errores que afectan la calidad de los reportes.

Solución implementada

Se ha desarrollado un pipeline automatizado orquestado en n8n que:

- Descarga el Excel desde Google Drive.
- Parsea, limpia y transforma los datos (fechas, nulos, tipos).
- Valida la estructura (campos obligatorios) y la semántica (email, región, cantidad>0).
- Carga los registros válidos en una hoja de Google Sheets (ventas_limpias) y los inválidos en una hoja de cuarentena (cuarentena).
- Calcula KPIs de calidad (completitud, tasa de error, latencia) y genera alertas automáticas.
- Registra logs detallados por cada etapa para auditoría.

Valor para la organización

- Reducción de tiempo: de 2 horas manuales a <1 minuto automático.
- Calidad de datos garantizada: cero errores de formato, correos inválidos o regiones mal escritas.
- Trazabilidad total: cada ejecución queda documentada con logs y registros en cuarentena.
- Monitoreo proactivo: alertas cuando la tasa de error supera el 5% o la completitud baja del 95%.

2. Justificación de la metodología PMBOK aplicada

Se ha seleccionado un enfoque adaptativo (ágil) dentro del marco del PMBOK, alineado con los principios DataOps de integración y entrega continua.

Razones técnicas

- Requisitos cambiantes: la estructura del Excel (columnas, tipos) puede evolucionar; el pipeline necesita adaptarse sin rediseños completos.
- Feedback rápido: los KPIs y logs permiten ajustar reglas de validación (ej: nuevas regiones) en horas.
- Entrega incremental: se desarrolló etapa por etapa (ingesta → limpieza → validación → carga → monitoreo), cada una funcional antes de pasar a la siguiente.

Comparación con enfoque predictivo (cascada)

Un modelo en cascada habría requerido especificar todas las reglas de negocio al inicio y

habría dificultado la incorporación de nuevas fuentes (ej: API REST adicional). El pipeline en n8n, con nodos Code modificables, permite iterar rápidamente ante cambios del negocio.

3. Planificación del proyecto

3.1 Product Backlog

Épica / Módulo	Tareas clave	Prioridad
Ingesta	Configurar OAuth2 Google Drive; implementar descarga; crear log de ingesta (registros, columnas).	Alta
Limpieza	Normalización de fechas (Excel serial → ISO); manejo de nulos; conversión de tipos; log de errores por fila.	Alta
Validación	Reglas estructurales (campos obligatorios); reglas semánticas (email regex, regiones, quantity>0, price>0); separación válidos/inválidos.	Alta
Carga	Configurar Google Sheets; escritura en ventas_limpias y cuarentena; uso de order_id como clave.	Media
Monitoreo	Cálculo de KPIs (completitud, tasa error, latencia); generación de alertas; log final consolidado.	Media
Documentación	Comentarios en código; README; Dockerfile; capturas de logs y ejecución.	Media

Pruebas y demo	Dataset de prueba; pruebas de borde (archivo vacío, datos corruptos); ensayo de presentación.	Alta
----------------	---	------

3.2 Roadmap del Proyecto (3 semanas)

El desarrollo se organizó en tres semanas de trabajo, conforme al tiempo asignado para el encargo:

- Semana 1: Análisis y Diseño
 - Levantamiento de requerimientos.
 - Identificación de la problemática.
 - Diseño de la arquitectura DataOps.
 - Selección de herramientas tecnológicas (n8n, Google Drive, Google Sheets, Docker, GitHub).
- Semana 2: Desarrollo e Implementación
 - Construcción del flujo automatizado en n8n.
 - Implementación de la ingesta de datos (Google Drive → parseo → log).
 - Desarrollo de procesos de limpieza y transformación (fechas, nulos, tipos).
 - Desarrollo de validación estructural y semántica.
 - Configuración de carga dual (válidos e inválidos) y alertas automáticas (KPIs).
- Semana 3: Evaluación y Documentación
 - Implementación de KPIs de monitoreo (completitud, tasa de error, latencia).
 - Pruebas funcionales con datos reales y casos borde.
 - Elaboración de documentación técnica (informe, comentarios en código, README).
 - Preparación de la presentación y demo funcional en vivo.

3.3 Carta Gantt (detalle por día / tarea)

Actividad	Semana 1	Semana 2	Semana 3
Levantamiento de requerimientos	X		
Diseño del pipeline	X		
Preparación de datos (Excel fuente)	X		

Ingesta (Google Drive → JSON)		X	
Limpieza y transformación		X	
Validación estructural y semántica		X	
Carga dual (válidos / cuarentena)		X	
Implementación de alertas y KPIs			X
Documentación (GitHub, Dockerfile)			X
Presentación final y demo			X

3.4 Herramienta de seguimiento: Trello

Se utiliza Trello con las siguientes listas:

- Backlog (tareas pendientes, priorizadas por épica).
- En curso (máximo 3 tareas por persona).
- En revisión (código revisado por otro integrante).
- Listo (tarea completada y probada).

Cada tarjeta contiene:

- Checklist de subtareas.
- Fechas de inicio y fin.
- Comentarios con capturas de logs y enlaces a commits de GitHub.
- Etiquetas de módulo (ingesta, limpieza, etc.).

4. Explicación técnica de cada etapa del pipeline (Actividades 1-4 EA2)

A continuación se detalla el flujo implementado en n8n, correspondiente a las 4 etapas clave del ciclo de vida del dato.

4.1 Ingesta

Nodos involucrados:

Manual Trigger → Google Drive → Spreadsheet File → Code (Log de Ingesta)

Proceso:

1. El usuario ejecuta el pipeline manualmente (demo).
2. El nodo Google Drive (autenticación OAuth2) descarga el archivo Excel desde una carpeta compartida. El ID del archivo se parametriza como variable de entorno.
3. Spreadsheet File lee el archivo, usa la primera fila como cabeceras y genera un objeto JSON por cada fila.
4. El nodo Code itera sobre todos los items, registra:
 - Cantidad de registros leídos.
 - Lista de columnas detectadas.
 - Timestamp de inicio.Si el archivo está vacío, lanza un error y detiene el flujo.

4.2 Limpieza y transformación

Nodo involucrado: Code (ETAPA 2 - Limpieza y Transformación)

Proceso:

- Convierte fechas: función excelSerialToDate transforma número serial de Excel a YYYY-MM-DD.
- Elimina espacios en blanco (trim) y normaliza mayúsculas/minúsculas (región a mayúscula, email a minúscula).
- Convierte quantity a entero y price a flotante. Si la conversión falla, agrega un error a _errors.
- Reemplaza valores null o undefined por cadena vacía.

Resultado:

- Objeto cleanedData (array de filas limpias, cada una con su propio _errors si los hubo).
- Log agregado: records_processed, records_with_errors, error_detail.

4.3 Validación estructural y semántica de los datos

Nodo involucrado: Code (ETAPA 3 - Validación)

Validación estructural (obligatoriedad)

- order_id, customer_name, product, date no pueden estar vacíos.

Validación semántica (reglas de negocio)

- quantity > 0
- price > 0
- Email: regex `^[^@s@]+@[^@s@]+\.[^@s@]+$`
- Región: pertenece a una lista predefinida (13 regiones chilenas, ej: RM, BIO, VAL, etc.)

Separación:

- Válidos → array validData (sin _errors).
- Inválidos → array invalidData (con _issues detallando la causa).

Se genera un validationLog con totales y un resumen de los inválidos.

4.4 Carga de datos

Nodos involucrados:

Code (ETAPA 4 - Preparar Carga) → Google Sheets (ventas_limpias)

Rama paralela: Code (Cuarentena) → Google Sheets (cuarentena)

Preparación de carga:

- Mapea los registros válidos a un nuevo esquema: order_id, customer_name, product, quantity, price, order_date (renombrado), email, region, loaded_at.
- Adjunta _pipeline_logs (logs de ingesta, limpieza, validación y carga) solo al primer item para evitar redundancia.

Carga principal (ventas_limpias):

- Usa appendOrUpdate con order_id como clave de coincidencia.
- Si el registro ya existe, actualiza; si no, lo inserta.

Cuarentena:

- Los registros inválidos se transforman en objetos con `order_id`, `raw_data` (JSON stringificado), `issues` (unidos por `|`) y `detected_at`.
- Se escriben en la hoja cuarentena (también con `appendOrUpdate`).

5. Plan de seguridad entorno DataOps (Leyes y cifrado)

5.1 Cumplimiento normativo

- Ley de Protección de Datos Personales (Chile – Ley 19.628):
 - Los campos customer_name y email son datos personales.
 - Se aplica seudonimización en los logs de depuración: el email se muestra truncado (mic***@example.com).
 - No se almacena ningún dato fuera de las plataformas Google (Drive y Sheets), las cuales cumplen con las cláusulas de confidencialidad.
 - Se asume que el e-commerce ha obtenido consentimiento de los clientes para procesar sus compras con fines analíticos.

5.2 Cifrado

- En tránsito: Las conexiones a Google APIs usan TLS 1.3.
- En reposo: Los archivos en Google Drive y las hojas de Sheets se cifran con AES-256 (por defecto en Google Cloud).
- Credenciales: Los tokens OAuth2 de n8n se almacenan cifrados en la base de datos interna de n8n (AES-256). Nunca se incluyen en el código ni en el repositorio.

5.3 Control de accesos

- Principio de mínimo privilegio: La cuenta de servicio de Google tiene acceso solo a la carpeta específica que contiene el Excel fuente y a las hojas ventas_limpias y cuarentena.
- MFA: Se exige autenticación multifactor para la cuenta de Google que genera los tokens.
- Auditoría: Los logs de n8n registran quién ejecutó el pipeline (usuario de n8n) y a qué hora.

6. Documentación del código con evidencias y repositorio GitHub

6.1 Repositorio GitHub

Link: https://github.com/SevenMinds07/E-Commerce_GestData

Contenido:

- pipeline_dataops.json – Exportación completa del flujo n8n (el código JavaScript incluido).
- Dockerfile – Imagen personalizada de n8n para este proyecto.
- docker-compose.yml – Orquestación con variables de entorno para credenciales.
- README.md – Instrucciones: clonar, configurar OAuth2, reemplazar IDs de archivos, ejecutar.
- logs/ejecucion_20250526.txt – Log de ejemplo (anónimo).

6.2 Evidencias (logs y capturas)

Log de ingesta:

Logs

Clear execution

ETAPA 1c - Log de Ingesta

Success in 11.79s

Ejecutar Pipeline (Manual)

ETAPA 1a - Descargar Excel ...

ETAPA 1b - Parsear Excel a J...

ETAPA 1c - Log de Ingesta

ETAPA 2 - Limpieza y Transf...

ETAPA 3 - Validación Estruct...

ETAPA 4 - Preparar Carga

Google Sheets - Hoja ventas...

KPI Monitoreo del Pipeline

Log Final - Auditoría

Cuarentena - Registros Invál...

Google Sheets - Hoja cuaren...

OUTPUT

order_id	customer_name	product	quantity	price	date	email	region
ORD-026	Isidora Vega	Monitor	4	476224	2025-01-09	isidoravega@gmail.com	OHI
ORD-027	undefined	Smartphone	4	20080	2025-01-10	camiliadiaz@hotmail.com	RM
ORD-028	Luis Pérez	Cable HDMI	6	153588	2025-03-07	luisperez@outlook.com	COQ
ORD-029	Sebastián Castro	Tablet	3	1202564	2025-03-15	sebastiancastro@hotmail.com	LLA
ORD-030	Felipe Morales	Teclado	2	208278	2025-03-26	felipemorales@outlook.com	LRI
ORD-031	Isidora Vega	Cable HDMI	1	1417147	2025-03-25	isidoravega@gmail.com	BIO
ORD-032	Javiera Fuentes	Cargador	2	526470	2025-01-25	javierafuentes@yahoo.com	COQ
ORD-033	Valentina Ramos	Auriculares	8	528882	2025-04-22	valentinaramos@yahoo.com	BIO
ORD-034	Andrés Mora	Monitor	1	1372646	2025-03-11	andresmora@gmail.com	RM
ORD-035	Camila Díaz	Mouse	7	1023463	2025-03-03	camiliadiaz@yahoo.com	COQ
ORD-036	Valentina Ramos	Disco SSD	1	823773	2025-02-03	valentinaramos@outlook.com	LLA
ORD-037	Andrés Mora	Impresora	8	329632	2025-01-25	andresmora@hotmail.com	MAU
ORD-038	Fernanda Lagos	Router	9	GRATIS	2025-04-06	fernadalagos@gmail.com	OHI
ORD-039	Tomás Navarro	Tablet	9	335180	2025-01-08	tomasnavarro@gmail.com	ARI
ORD-040	Carlos López	Smartphone	2	1421023	2025-04-21	carloslopez@yahoo.com	COQ
ORD-041	Fernanda Lagos	Teclado	10	1251797	2025-01-06	fernadalagos@gmail.com	TAR
ORD-042	Fernanda Lagos	Smartphone	9	668475	2025-04-30	fernandalagos@hotmail.com	MAU
ORD-043	Javiera Fuentes	Teclado	5	835023	2025-01-17	javierafuentes@yahoo.com	MAU
ORD-044	Carlos López	Laptop	8	1307665	2025-03-14	carloslopez@gmail.com	BIO
ORD-045	Paula Soto	Auriculares	3	736924	2025-04-23	paulasoto@hotmail.com	BIO
ORD-046	Valentina Ramos	Memoria RAM	9	1480430	2025-02-08	valentinaramos@gmail.com	TAR
ORD-047	Andrés Mora	Auriculares	2	288628	2025-02-03	andresmora@gmail.com	BIO
ORD-048	Pedro Silva	Auriculares	5	1273420	2025-09-27	pedrosilva@hotmail.com	OHI
ORD-049	Diego Muñoz	Tablet	8	53639	2025-04-26	diegomunoz@gmail.com	RM
ORD-050	Diego Muñoz	Laptop	1	704518	2025-04-09	diegomunoz@outlook.com	VAL

Log de limpieza

Logs

Clear execution

ETAPA 2 - Limpieza y Transformación

Success in 10ms

Ejecutar Pipeline (Manual)

ETAPA 1a - Descargar Excel ...

ETAPA 1b - Parsear Excel a J...

ETAPA 1c - Log de Ingesta

ETAPA 2 - Limpieza y Transf...

ETAPA 3 - Validación Estruct...

ETAPA 4 - Preparar Carga

Google Sheets - Hoja ventas...

KPI Monitoreo del Pipeline

Log Final - Auditoría

Cuarentena - Registros Invál...

Google Sheets - Hoja cuaren...

OUTPUT

cleanedData	log	ingestLog
0 order_id : ORD-001 customer_name : María Torres product : Laptop quantity : 5 price : 518575 date : 2025-01-29 email : mariatorres@gmail.com region : VAL ingestLog stage : INGESTA timestamp : 2026-05-27T00:42:05.138Z records_read : 100 source : Google Drive — ventas_ecommerce.xlsx columns 0 : order_id 1 : customer_name 2 : product 3 : quantity 4 : price 5 : date 6 : email 7 : region status : OK _errors : [empty array]	stage : LIMPIEZA timestamp : 2026-05-27T00:42:05.159Z records_processed : 100 records_with_errors : 3 error_detail 0 order_id : ORD-038 errors 0 : price no es número: GRATIS 1 order_id : ORD-071 errors 0 : price no es número: GRATIS 2 order_id : ORD-082 errors 0 : price no es número: GRATIS status : OK	stage : INGESTA timestamp : 2026-05-27T00:42:05.138Z records_read : 100 source : Google Drive — ventas_ecommerce.xlsx columns 0 : order_id 1 : customer_name 2 : product 3 : quantity 4 : price 5 : date 6 : email 7 : region status : OK
1 order_id : ORD-002 customer_name : Andrés Mora product : Monitor quantity : 10		

Log de validación:

Logs

Clear execution

ETAPA 3 - Validación Estructural y Semántica

Success in 12ms

Ejecutar Pipeline (Manual)

ETAPA 1a - Descargar Excel ...

ETAPA 1b - Parsear Excel a J...

ETAPA 1c - Log de Ingesta

ETAPA 2 - Limpieza y Transf...

ETAPA 3 - Validación Estruct...

ETAPA 4 - Preparar Carga

Google Sheets - Hoja ventas...

KPI Monitoreo del Pipeline

Log Final - Auditoría

Cuarentena - Registros Invál...

Google Sheets - Hoja cuaren...

OUTPUT

validData	invalidData	log	ingestLog	cleanLog
0 order_id : ORD-001 customer_name : María Torres product : Laptop quantity : 5 price : 518575 date : 2025-01-29 email : mariatorres@gmail.com region : VAL ingestLog stage : INGESTA timestamp : 2026-05-27T00:42:05.138Z records_read : 100 source : Google Drive — ventas_ecommerce.xlsx columns 0 : order_id 1 : customer_name 2 : product 3 : quantity 4 : price 5 : date 6 : email 7 : region status : OK _valid : true	0 order_id : ORD-021 customer_name : Andrés Mora product : Cargador quantity : -9 price : 6199 date : 2025-03-18 email : andresmora@yahoo.com region : OHI _valid : false _issues 0 : [SEM] quantity debe ser > 0, valor: -9 1 order_id : ORD-022 customer_name : Matías Herrera product : Hub USB quantity : 5 price : 507167 date : 2025-01-08 email : matiasherrerasinarroba region : COQ _valid : false _issues 0 : [SEM] email inválido: matiasherrerasinarroba 2 order_id : ORD-027 product : Smartphone quantity : 4	stage : VALIDACION timestamp : 2026-05-27T00:42:05.172Z total_records : 100 valid_records : 90 invalid_records : 10 invalid_detail 0 order_id : ORD-021 issues 0 : [SEM] quantity debe ser > 0, valor: -9 1 order_id : ORD-022 issues 0 : [SEM] email inválido: matiasherrerasinarroba 2 order_id : ORD-027 issues 0 : [STRUCT] customer_name vacío 3 order_id : ORD-038 issues 0 : price no es número: GRATIS 1 : [SEM] price debe ser > 0, valor: null 4 order_id : ORD-057 issues 0 : [SEM] quantity debe ser > 0, valor: -8	stage : INGESTA timestamp : 2026-05-27T00:42:05.138Z records_read : 100 source : Google Drive — ventas_ecommerce.xlsx columns 0 : order_id 1 : customer_name 2 : product 3 : quantity 4 : price 5 : date 6 : email 7 : region status : OK	stage : LIMPIEZA timestamp : 2026-05-27T00:42:05.159Z records_processed : 100 records_with_errors : 3 error_detail 0 order_id : ORD-038 errors 0 : price no es número: GRATIS 1 order_id : ORD-071 errors 0 : price no es número: GRATIS 2 order_id : ORD-082 errors 0 : price no es número: GRATIS status : OK

Log de KPI:

pipeline	run_timestamp	kpis	alerts	stage_logs
Pipeline DataOps E-commerce	2026-05-27T01:20:26.845Z	total_records_ingested : 100 records_valid : 90 records_invalid : 10 records_loaded : 90 complettitud_pct : 90 tasa_error_pct : 10	0 : ▲ ALERTA: Tasa de error supera el 5% 1 : ▲ ALERTA: Completitud bajo el 95%	ingest stage : INGESTA timestamp : 2026-05-27T01:20:25.703Z records_read : 100 source : Google Drive — ventas_ecommerce.xlsx columns 0 : order_id 1 : customer_name 2 : product 3 : quantity 4 : price 5 : date 6 : email 7 : region status : OK clean stage : LIMPIEZA timestamp : 2026-05-27T01:20:25.722Z records_processed : 100 records_with_errors : 3 error_detail 0 order_id : ORD-038 errors 0 : price no es número: GRATIS 1 order_id : ORD-071 errors 0 : price no es número: GRATIS 2

7. Estrategia de los principales KPI de monitoreo

KPI	Fórmula	Umbral de alerta	Acción correctiva
Completitud	$(\text{Registros válidos} / \text{Total ingeridos}) \times 100$	< 95%	Notificar al analista de datos; revisar reglas de validación (puede ser cambio en el negocio).
Tasa de error	$(\text{Registros inválidos} / \text{Total ingeridos}) \times 100$	> 5%	Inspeccionar hoja cuarentena; corregir datos fuente o añadir nuevas reglas de limpieza.
Latencia del pipeline	Tiempo (ms) desde fin de ingesta hasta fin de carga	> 30.000 ms (30 seg)	Revisar conexión a Google APIs; optimizar bucles en nodos Code; aumentar recursos de n8n.

Volumen procesado	Número de registros por ejecución	(Solo histórico)	Útil para planificar escalabilidad y migrar a procesamiento batch si supera 10k registros/día.
-------------------	-----------------------------------	------------------	--

Implementación en el pipeline:

El nodo KPI Monitoreo del Pipeline lee los logs encadenados (ingesta, limpieza, validación, carga) y calcula automáticamente estos KPIs. Si se supera un umbral, se agrega una alerta al objeto alerts. En versiones futuras se conectará a un webhook de Slack o correo SMTP.

8. Conclusiones y próximos pasos del proyecto

Conclusiones alcanzadas

- Se ha implementado un pipeline DataOps completamente funcional en n8n, cubriendo las 4 etapas obligatorias (ingesta, limpieza, validación, carga).
- El flujo es reproducible y auditable gracias a los logs generados en cada etapa y al registro en cuarentena de datos rechazados.
- Los KPIs de monitoreo permiten a la organización evaluar la calidad de los datos en tiempo real y reaccionar ante desviaciones.
- Se cumplió con la planificación establecida en el RoadMap, entregando el proyecto dentro de las 6 semanas (semanas 5 a 11).

Próximos pasos propuestos

1. Automatización temporal: cambiar el Manual Trigger por un trigger de cron (ejecución diaria a las 3 AM).
2. Notificaciones proactivas: integrar nodo de Slack o Email para enviar alertas cuando la tasa de error supere el 5%.
3. Data lineage avanzado: registrar en una base de datos (PostgreSQL) el historial de transformaciones aplicadas a cada order_id.
4. Escalabilidad: si el volumen crece a más de 10.000 registros por día, migrar las etapas de limpieza y validación a un proceso Python con Pandas y orquestarlo con Apache Airflow (n8n seguiría como orquestador ligero).
5. Dashboard de calidad: conectar las hojas ventas_limpias y cuarentena a Looker Studio para visualizar tendencias de completitud y tasa de error por semana.